Útvonalfeldolgozási megoldások napjainkban

Csuport Ákos
ckcbs0@inf.elte.hu

Eötvös Loránd Tudományegyetem Informatikai Kar

2026. 10. 07.

1 Bevezetés

Az útvonalak elemzése az informatikában egy különösen aktív terület. Számos algoritmus és módszer jelent meg megtett útvonalak különböző fajtájú feldolgozására: összegzés, klasszifikáció, predikció, stb. [3]

Indokolhatja a terület felkapottságát, hogy számos területen, főleg olyanokon, amelyek valamilyen módon a közlekedési infrastruktúrát érintik, szükség van útvonaladatok összegzésére, összehasonlítására, következő lépések megjóslására, [2] vagy tervezés alatt lévő megoldások esetén előzetes forgalmi modellek létrehozására a még nem kivitelezett hálózatokon [3]. Ilyenek többek közt a településfejlesztés [6] [3], útvonaltervezési szolgáltatások [3] vagy a közlekedésszervezés optimalizációja [6].

Eleinte az utak feldolgozására gyakorta használtak olyan tradicionális gépi tanulási technikákat, mint a probabilisztikus modellek, bayes-i hálózatok, vagy a k legközelebbi szomszéd algoritmusa [2]. A neurális hálók megjelenését követően ezek legkülönbözőbb változatait lett szokásos felhasználni útvonalelemzésekhez [3] [6] [2].

Az útvonalak, illetve szegmenseinek vektorokba történő beágyazását, és neuronhálókkal történő feldolgozását útvonalreprezentációs tanulásnak (*TRL, Trajectory Representation Learning*) szokás hívni [6]. Az ilyen megoldások mögött többnyire rekurrens neuronhálók állnak, de egyes kivitelezésekben a transzformer modellt is alkalmazzák. [6] Ez a megoldás népszerű és hatékony bizonyos útvonalakkal kapcsolatos elemzések végrehajtására, de a TRL megoldások jellemzően csak bizonyos feladattípusok megoldására jók (hasonlóság, útvonalak klasszifikációja, útvonalak úthálózatra igazítása) [3] [6], így ezen a megközelítésen kívül is bőven van helye útvonalelemzési technikáknak. Ebbe beletartoznak gráfok feldolgozására szolgáló konvolúciós hálók [2], illetve a TRL-nél már említett transzformer modell [4] erős és utóbbi időben nagy nyelvi modellekhez gyakran alkalma-

zott természetes nyelvfeldolgozásra való rátermettségének felhasználása az útvonalak nyelvként történő formalizálásával, ami bemenetként használható.

2 Kapcsolódó művek

Mivel az útvonalak feldolgozása egy kellőképp aktív téma, számos cikk foglalkozott vele akár csak az utóbbi években is [3]. A RED [6] (*Road-aware masking strategy, Embedding, Dual-objective task learning*) egy önfelügyelő tanulást alkalmazó, transzformer modellre épülő TRL-keretrendszer. Mint a többi TRL megközelítés, az útvonalak egyes szegmenseit vektorokba ágyazza, az úthálózatra illeszti a megtett útról gyűjtött helyadatokat, és két feladattal tanítja magát: a RED transzformere az útvonal következő szegmenseit próbálja előre eltalálni, a dekóder pedig a teljes útvonalakat rekonstruálja. [6]

A betanított modell számos feladatra képes, amit egy TRL megoldás nyújthat. Az útvonalreprezentációs tanulás lehetőségeit kihasználva az útvonalak olyan szempontjai szerint is képes hasonlítást, klasszifikációt és predikciót végezni, melyet legfeljebb egy-két vetélytárs tud a kategóriában. Ebbe beletartozik az útvonalak nemcsak térbeli, hanem időbeli elemzése is, valamint az útvonalak felhasználókhoz is társítva vannak, ezáltal felhasználói preferenciákat is képes kimutatni a keretrendszer. Az eredmények alapján a RED a legtöbb esetben több mint 5javítja a legjobb baseline módszer által elért pontosságot [6].

Éppen a TRL modellek korlátozásainak átlépésére készült egy másik technika, a KAFY [3]. A KAFY a RED-hez hasonlít annyiban, hogy időben és térben is képes útvonalakat feldolgozni, ráadásul szintén felhasználja a transzformer modellt, viszont az útvonal szegmenseinek vektorokba ágyazása helyett az útvonalakat egy nyelvként [1] kódolja, majd (emberi nyelven még nem betanított) transzformereket használ fel. Ennek célja a transzformer modell teljesítményének kihasználása a nyelvfeldolgozásban, amit olyan rendszerek, mint a BERT [1] vagy a GPT [5] korábban már demonstráltak. Maga a kialakított nyelv az útvonalak és emberi nyelveken kifejezett szövegek közti megfeleltetésekre épül: a nyelv különböző nyelvi elemek (pl. szavak) sorozata, az útvonal pedig koordináták sorozata. Egy szövegben, hogy értelmezhessük, a nyelvi elemek kapcsolatainak szemantikailag helyesnek kell lenniük, hasonlóképp van az útvonal egyes pontjain készült tér- és időbeli pontok szemantikát alkotnak. Így, míg a TRL rendszereknél előre meghatározott, legtöbbször egy vagy néhány, feladatra betanított neuronhálók vannak a modellhez szorosan kötődő vektorbeágyazással, a KAFY egy általános, NLP-ben használatoshoz hasonló tokensorozatot készít az útvonalakból, amit a KAFY-ban demonstrált három transzformer (BERT, GPT-2 és T-5) öt feladatot lát el: összegzés, predikció, útvonalgenerálás, imputáció és klasszifikáció [3], azonban a KAFY moduláris és kiegészíthető további, egyedileg hangolt transzformerrel, melyek általánosan fel tudják dolgozni az útvonalat reprezentáló tokensorozatot.

Egy harmadik útvonalfeldolgozási modell, az MDTP (*Multi-source Deep Traffic Prediction Framework*) [2] az eddigi említett megközelítésekkel el-

lentétben a vizsgált területet régiókra bontja, amik gráfot alkotnak, és a köztük haladó éleken van reprezentálva a köztük haladó forgalom fajtája (pl. taxi, kerékpár) és mennyisége, időintervallumokra leosztva. Az MDTP korrelációkat mutat ki időszak és járműtípus szempontjából a különböző régiók közti forgalomban, erre tartalmaz egy komponenst, mely vizualizálja az adatokat, illetve az eltelt időintervallumok alapján becsli a következő intervallumban lebonyolodó forgalmat [2]. Ehhez egy gráfkonvolúciós hálót használ (GCN), ami jó választás egy térben rögzített területen a forgalom régiók közti lebonyolódásának elemzésére [2].

References

[1] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding, 2018.

[2] Ziquan Fang, Lu Pan, Lu Chen, Yuntao Du, and Yunjun Gao. Mdtp: a multi-source deep traffic prediction framework over spatio-temporal trajectory data. *Proceedings of the VLDB Endowment*, 14(8):1289–1297, April 2021.

[3] Youssef Hussein and Mohamed F. Mokbel. Kafy : An extensible and scalable transformers-based system for trajectory data analysis. *Proceedings of the VLDB Endowment*, 19(11):3385–3399, July 2026.

[4] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2017.

[5] Gokul Yenduri, Ramalingam M, Chemmalar Selvi G, Supriya Y, Gautam Srivastava, Praveen Kumar Reddy Maddikunta, Deepti Raj G, Rutvij H Jhaveri, Prabadevi B, Weizheng Wang, Athanasios V. Vasilakos, and Thippa Reddy Gadekallu. Generative pre-trained transformer: A comprehensive review on enabling technologies, potential applications, emerging challenges, and future directions, 2023.

[6] Silin Zhou, Shuo Shang, Lisi Chen, Christian S. Jensen, and Panos Kalnis. Red: Effective trajectory representation learning with comprehensive information. *Proceedings of the VLDB Endowment*, 18(2):80–92, October 2024.